ОТЧЁТ

по проверке модели прогноза стоимости недвижимости на тестовых данных

Выполнил: Туляшев Ильяс Венерович
Группа: 23п-4

1. Описание модели

Задача: регрессия — прогноз цены объявления о продаже объекта недвижимости (валюта TRY).

Данные: набор real_estate_data.csv (403 486 объявлений). Использованы объявления в валюте TRY с положительной ценой и типом «продажа» (listing_type = 1). Экстремальные выбросы цены удалены (оставлены значения между 2-м и 98-м перцентилями). После очистки получено 273 252 объекта.

Признаки: тип недвижимости (sub_type), тип отопления (heating_type), площадь (size) и её логарифм, число комнат (сумма, например 3+1 → 4), возраст здания, этажность здания, срок размещения объявления (tom), длительность объявления в днях (listing_days).

Предобработка: числовые признаки — заполнение пропусков медианой и стандартизация (StandardScaler); категориальные — заполнение самым частым значением и One-Hot-кодирование. Все преобразователи обучались только на обучающей выборке.

Разбиение: обучающая 70% (191 276), валидационная 15% (40 988), тестовая 15% (40 988); random_state = 42.

Алгоритмы: сравнивались Ridge-регрессия, DecisionTreeRegressor, RandomForestRegressor и GradientBoostingRegressor. Гиперпараметры подбирались перебором по сетке (GridSearchCV / RandomizedSearchCV) по метрике MAE с кросс-валидацией на подвыборке обучающих данных; затем модели обучались на всей обучающей выборке.

Итоговая модель: RandomForest (случайный лес), параметры: n_estimators = 60, max_depth = 12, min_samples_leaf = 2. Модель выбрана по наименьшему MAE на валидационной выборке; итоговый пайплайн (предобработка + модель) переобучен на объединении обучающей и валидационной выборок.

Метрики качества на валидационной выборке

Модель	MAE, TRY	RMSE, TRY	MAPE, %	R^2
Ridge	145 064	231 600	45,8	0,358
DecisionTree	139 265	225 511	43,8	0,391
RandomForest	133 032	216 532	41,5	0,439
GradientBoosting	136 299	221 172	42,7	0,414

На отложенной тестовой выборке (40 988 объектов) лучшая модель показала: MAE = 132 651 TRY, RMSE = 215 550 TRY, MAPE = 41,4%, R^2 = 0,446.

2. Проверка модели на 20 тестовых объектах

Прогнозы модели для 20 объектов приведены в таблице. Полная таблица со всеми исходными столбцами, прогнозом, ошибками, ФИО и группой сохранена в файле

result_real_estate_samples.csv. Прочерк означает пропуск значения в исходных данных (при прогнозировании пропуски заполняются медианой/модой обучающей выборки).

№	id	Тип	Площадь, м²	Комн.	Возраст	Отопление	Цена факт, TRY	Прогноз, TRY	|Ошибка|, TRY
1	384040	Daire	170.0	3+1	—	—	235 000	367 982	132 982
2	36334	Daire	130.0	3+1	21-25 arası	Klima	158 000	277 107	119 107
3	9575	Daire	210.0	4+2	6-10 arası	Kalorifer (Doğalgaz)	565 000	464 661	100 339
4	239643	Daire	75.0	2+1	6-10 arası	Kombi (Doğalgaz)	130 000	231 419	101 419
5	391233	Daire	—	1+1	—	—	110 000	172 267	62 267
6	153742	Daire	200.0	4+2	5	Kombi (Doğalgaz)	450 000	441 698	8 302
7	300679	Daire	—	3+1	6-10 arası	Merkezi Sistem (Isı Payı Ölçer)	400 000	407 508	7 508
8	76128	Daire	80.0	2+1	6-10 arası	Klima	230 000	256 561	26 561
9	117852	Daire	—	3+1	0	Kombi (Doğalgaz)	215 000	282 928	67 928
10	121393	Daire	140.0	3+1	0	Kombi (Doğalgaz)	650 000	327 623	322 377
11	60338	Daire	160.0	3+1	16-20 arası	Klima	150 000	347 858	197 858
12	71417	Daire	—	5+1	21-25 arası	Klima	365 000	457 463	92 463
13	95074	Daire	—	3+1	3	Kombi (Doğalgaz)	397 500	392 228	5 272
14	232981	Daire	—	2+1	2	Kombi (Doğalgaz)	468 000	228 309	239 691
15	313653	Daire	147.0	3+1	0	Merkezi Sistem (Isı Payı Ölçer)	475 000	575 772	100 772
16	114741	Daire	140.0	3+1	0	Kombi (Doğalgaz)	181 000	367 367	186 367
17	85539	Villa	—	3+1	0	Klima	750 000	617 545	132 455
18	85442	Villa	140.0	3+1	0	Klima	575 000	588 476	13 476
19	223916	Daire	—	4+1	1	Kombi (Doğalgaz)	315 000	390 921	75 921
20	324974	Daire	—	3+1	0	Merkezi Sistem (Isı Payı Ölçer)	265 000	371 111	106 111

3. Расчёт метрик

Метрики рассчитаны вручную по формулам и с помощью библиотеки scikit-learn (n — число объектов, y_i — фактическая цена, $\hat{y}_i$ — прогноз, $\bar{y}$ — средняя фактическая цена):

- $MAE = (1/n) \cdot \Sigma |y_i - \hat{y}_i|$;
- $RMSE = \sqrt{((1/n) \cdot \Sigma (y_i - \hat{y}_i)^2)}$;
- $R^2 = 1 - \Sigma (y_i - \hat{y}_i)^2 / \Sigma (y_i - \bar{y})^2$.

Метрика	Вручную	scikit-learn	Функция
MAE, TRY	104 958,91	104 958,91	mean_absolute_error
RMSE, TRY	132 341,90	132 341,90	mean_squared_error(...)**0.5

Метрика	Вручную	scikit-learn	Функция
R^2	0,4666	0,4666	r2_score

Значения, рассчитанные вручную и методами библиотеки, совпадают, что подтверждает корректность расчётов.

4. Анализ результатов

- Средняя фактическая цена в тестовой выборке — 354 225 TRY. MAE = 104 959 TRY, то есть в среднем модель ошибается примерно на 29,6% от средней цены; медианная абсолютная ошибка — 100 556 TRY. Средняя процентная ошибка (MAPE) — 39,9%.
- RMSE (132 342 TRY) превышает MAE, поскольку квадратичная метрика сильнее штрафует крупные промахи.
- R^2 = 0,467: модель объясняет около 47% дисперсии цены на данной выборке. Это согласуется с результатом на большой тестовой выборке (R^2 = 0,446) — качество умеренное.
- Средняя ошибка со знаком (прогноз − факт) равна 24 115 TRY: модель в среднем завышает цену (завышено 14 объектов, занижено 6).
- Наибольшие ошибки получены для объектов № 10 (факт 650 000 TRY, прогноз 327 623 TRY), № 14 (факт 468 000, прогноз 228 309) и № 11 (факт 150 000, прогноз 347 858). Вероятная причина — признаки, не входящие в модель: район и адрес, состояние ремонта, этаж квартиры.
- У 9 из 20 объектов площадь не указана; площадь — важнейший ценовой фактор, и её замена медианой снижает точность прогноза для этих объектов.
- Выборка из 20 объектов мала, поэтому метрики на ней нестабильны: один-два крупных промаха заметно меняют RMSE и R^2.

Ограничения и возможные улучшения

Модель не учитывает местоположение (признак address исключён из-за большого числа уникальных значений) и обучена только на объявлениях о продаже в TRY. Качество можно повысить, добавив признак района/города (например, через target encoding), используя логарифм цены в качестве целевой переменной, а также более тщательно подобрав гиперпараметры на всей обучающей выборке и попробовав градиентный бустинг (LightGBM, CatBoost).

5. Вывод

Лучшей моделью по MAE на валидации признан RandomForest. На 20 тестовых объектах получены MAE = 104 959 TRY, RMSE = 132 342 TRY, R^2 = 0,467. Ручной расчёт метрик совпал с расчётом scikit-learn. Качество прогноза умеренное: модель пригодна как грубый ориентир стоимости, но не заменяет оценку специалиста, так как не учитывает район и состояние объекта.